

Διαχείριση Σύνθετων Δεδομένων
ΕΡΓΑΣΙΑ 1 – Αποτίμηση ερωτημάτων
REPORT

Ευάγγελος Μπασδαβάνος

AM 4962

Μέρος 1 (group-by with aggregation)

Στο μέρος 1 πρέπει να επιτευχθεί υπολογισμός του αποτελέσματος τελεστών συνάθροισης σε έναν πίνακα με χρήση ταξινόμησης. Για να γίνει αυτό πρώτα με την `read_csv_file` διαβάζει όλο το csv αρχείο και το αποθηκεύει στην λίστα `data`. Έπειτα, δημιουργείται μία νέα ανανεωμένη λίστα η οποία δεν περιέχει όποια στήλη από το csv αρχείο δεν είναι ούτε το `attribute` ομαδοποίησης ούτε το `attribute` συνάθροισης. Αυτό το κάνει η μέθοδος `updated_list()` η οποία ελέγχει στοιχείο-στοιχείο και όποιο στοιχείο δεν ανήκει στην στήλη που είναι το `attribute` συνάθροισης ή ομαδοποίησης το αγνοεί και δεν το προσθέτει στην νέα λίστα. Στο τέλος επιστρέφει μια νέα ανανεωμένη λίστα, την `new_data`, η οποία περιέχει μόνο όσα στοιχεία πληρούν τις συνθήκες. Έπειτα ξεκινά η ταξινόμηση με κλήση της `group_by_with_aggregation()`. Στην συγκεκριμένη εκτελείται ο αλγόριθμος της `merge sort`. Χωρίζει την λίστα στην μέση και καλείται αναδρομικά με το `left_half` και το `right_half` έως ότου το μήκος του καθενός είναι ίσο με 1. Μετά κάνει και το `merge` ελέγχοντας τα `grouping_attributes`. Όταν το `grouping_attribute` της αριστερής είναι μικρότερο από της δεξιάς, τότε προσθέτει στην λίστα `merged` το αριστερό. Και με την ίδια διαδικασία προσθέτει το δεξί αν είναι μικρότερο από το αριστερό. Στην περίπτωση που είναι ίσα, τότε λαμβάνουμε υπόψη τις συναρτήσεις συνάθροισης. Αναλόγως ποια συνάρτηση δόθηκε στο `command line`, κάνει την πράξη και στο τέλος προσθέτει στην `merged` την δυάδα (`grouping_attribute` του αριστερού, το αποτέλεσμα της συνάθροισης). Προσθέτουμε μόνο του αριστερού και όχι και των δύο ώστε να μην υπάρχουν `duplicates`. Δεν υπάρχει κάποια διαφορά αφού ούτως ή άλλως είναι ίσα. Έπειτα στην περίπτωση που το αριστερό ή το δεξί είναι μεγαλύτερο σε μήκος από το άλλο, τότε τα εναπομείναντα απλά προστίθενται στην `merged`. Τέλος, για να αποθηκεύσω τα αποτελέσματα που παράχθηκαν, υλοποίησα την μέθοδο `save_to_csv()` η οποία απλά δέχεται σαν όρισμα την λίστα που παρήγαγε η μέθοδος `group_by_with_aggregation()` και ένα όνομα αρχείου που θα αποθηκεύσουμε τα δεδομένα, στην δική μας περίπτωση το `O1.csv`. Έπειτα, γράφει κάθε λίστα που παράχθηκε γραμμή-γραμμή στο csv αρχείο.

Διαχείριση Σύνθετων Δεδομένων
ΕΡΓΑΣΙΑ 1 – Αποτίμηση ερωτημάτων
REPORT

Μέρος 2 (merge join)

Στην συγκεκριμένη άσκηση υλοποίησα την `def merge join` η οποία διαβάσει ταυτόχρονα τα δύο αρχεία και παράγει την φυσική συνένωση (`natural join`) τους με σχήμα (A,B,C,D,E). Για να το επιτύχει αυτό, παίρνει σαν όρισμα τα δύο αρχεία και αρχίζει να διαβάσει γραμμή-γραμμή το αρχείο R και διαβάσει την πρώτη γραμμή του αρχείου S. Μόλις εντοπίσει την πρώτη γραμμή του R στην οποία το πρώτο στοιχείο της είναι ίσο με το δεύτερο στοιχείο της γραμμής της S, τότε όσο παραμένουν ίσα αποθηκεύει σε μία νέα λίστα, την `temp`, τα στοιχεία με την σειρά (A,B,C,D,E) και προχωρά στην επόμενη γραμμή του S. Όταν σταματήσουν να είναι ίσες οι τιμές, τότε συνεχίζει να διαβάσει τις επόμενες γραμμές του R έως ότου ξανά εντοπίσει δύο ίσες τιμές και κάνει την προηγούμενη διαδικασία ξανά από την αρχή. Με αυτόν τον τρόπο καταφέρνω να παράγω την φυσική συνένωση των δύο πινάκων χωρίς να διαβάζω εξ ολοκλήρου το R.csv ή/και το S.csv πριν αρχίσει να παράγει αποτελέσματα. Τέλος, για να αποθηκεύσω τα αποτελέσματα που παράχθηκαν, υλοποίησα την μέθοδο `save_to_csv()` η οποία απλά δέχεται σαν όρισμα την λίστα που παρήγαγε η μέθοδος `merge_join()` και ένα όνομα αρχείου που θα αποθηκεύσουμε τα δεδομένα, στην δική μας περίπτωση το O2.csv. Έπειτα, γράφει κάθε λίστα που παράχθηκε γραμμή-γραμμή στο csv αρχείο.

Μέρος 3 (composite query)

Στην άσκηση 3 υλοποίησα την μέθοδο `composite_query(fileS,fileR)`. Ακολουθώντας την ίδια λογική με την δεύτερη άσκηση, αρχίζει να διαβάσει γραμμή-γραμμή το αρχείο R και διαβάσει την πρώτη γραμμή του αρχείου S. Μόλις εντοπίσει την πρώτη γραμμή του R στην οποία το πρώτο στοιχείο της είναι ίσο με το δεύτερο στοιχείο της γραμμής της S και το τρίτο στοιχείο της γραμμής του S είναι ίσο με 7, τότε όσο οι παραπάνω συνθήκες ισχύουν, περνάω σε μια μεταβλητή `sum` το άθροισμα όλων των S.E και τέλος αποθηκεύω σε μία νέα λίστα, την `temp`, τα στοιχεία S.A και `SUM(S.E)` και την προσθέτω στην λίστα `data`, η οποία είναι αυτή που θα γραφτεί στο τέλος στο csv αρχείο. Μετά προχωρά στην επόμενη γραμμή του S. Στην περίπτωση που το πρώτο στοιχείο της είναι ίσο με το δεύτερο στοιχείο της γραμμής της S και το τρίτο στοιχείο της γραμμής του S δεν είναι ίσο με 7, τότε απλά προχωρά στην επόμενη γραμμή του S και δεν αποθηκεύει τίποτα. Με αυτόν τον τρόπο, καταφέρνω να αποτιμήσω την σύνθετη ερώτηση με ένα μόνο πέρασμα πάνω από τα αρχεία. Τέλος, για να αποθηκεύσω τα αποτελέσματα που παράχθηκαν, υλοποίησα την μέθοδο `save_to_csv()` η οποία απλά δέχεται σαν όρισμα την λίστα που παρήγαγε η μέθοδος `composite_query()` και ένα όνομα αρχείου που θα αποθηκεύσουμε τα δεδομένα, στην δική μας περίπτωση το O3.csv. Έπειτα, γράφει κάθε λίστα που παράχθηκε γραμμή-γραμμή στο csv αρχείο.