

Διαχείριση Σύνθετων Δεδομένων
ΕΡΓΑΣΙΑ 2 – Χωρικά Δεδομένα
REPORT

Ευάγγελος Μπασδαβάνος

AM: 4962

Μέρος 1

Το πρόγραμμα υλοποιεί την τεχνική sort-tille-recursive (STR) και διαβάζει δεδομένα από το αρχείο και φτιάχνει ένα R-tree στη μνήμη για αυτά. Όστε να επιτευχθεί η σωστή λειτουργία του αλγορίθμου δημιουργήθηκαν οι κλάσεις: Point, η οποία είναι υπεύθυνη για τις λειτουργίες των αντικειμένων Point, η MBR η οποία είναι υπεύθυνη για τα αντικείμενα MBR και η Node η οποία περιλαμβάνει τις λειτουργίες των κόμβων. Αρχικά, φορτώνονται σημεία από ένα αρχείο κειμένου που περιέχει συντεταγμένες (x, y). Όλα τα σημεία που φορτώνονται από το αρχείο, τοποθετούνται σε μία λίστα από αντικείμενα Point με κάθε στοιχείο της λίστας να είναι της μορφής (recordId, x,y). Έπειτα, τα σημεία ταξινομούνται βάσει των συντεταγμένων x και οργανώνονται σε λωρίδες (stripes). Δημιουργούνται $\text{ceil}(\text{numberOfPoints} / (1024 / (8+8+4)))$ leaf nodes και $\text{ceil}(\text{sqrt}(\text{numberOfLeafNodes}))$ stripes. Κάθε λωρίδα περιέχει μία ομάδα σημείων, με μέγιστο αριθμό σημείων ανά λωρίδα να είναι $\text{numberOfStripes} * \text{leafNodeCapacity}$. Μετά, όλα τα σημεία, στο κάθε stripe ξεχωριστά, ταξινομούνται βάσει των συντεταγμένων y. Το capacity των leaf nodes είναι $\text{floor}(1024 / (8+8+4)) = 51$, οπότε σε κάθε λωρίδα οι κόμβοι-φύλλα έχουν είτε 51 φύλλα είτε όσα απομένουν στο stripe, αν είναι λιγότερα από 51. Στη συνέχεια, δημιουργούνται κόμβοι φύλλα για κάθε λωρίδα, τα οποία περιέχουν τα σημεία αυτής της λωρίδας. Μετά, τα φύλλα συγκεντρώνονται και οργανώνονται σε εσωτερικούς κόμβους. Κάθε εσωτερικός κόμβος έχει χωρητικότητα για 28 κόμβους. Κατά την διαδικασία δημιουργίας των εσωτερικών κόμβων ελέγχονται ένας-ένας οι κόμβοι του κατώτερου επιπέδου, βρίσκονται οι ελάχιστες κι μέγιστες τιμές των x και y συντεταγμένων και δημιουργείται ένα αντικείμενο mbr το οποίο δέχεται ως ορίσματα το nodeId του mbr και τις συντεταγμένες, και τοποθετείται σε μία λίστα από mbrs. Μετά, για κάθε 28 mbrs (ή λιγότερα αν είναι τα τελευταία εναπομείναντα) δημιουργείται νέος κόμβος και προστίθεται στον πίνακα nodes. Όσο το μήκος της λίστας στην οποία αποθηκεύονται οι κόμβοι του παραπάνω επιπέδου είναι μεγαλύτερο από 1, επαναλαμβάνεται η διαδικασία ώστε να επιτευχθεί η παραγωγή του δέντρου. Όταν γίνει 1, δηλαδή υπάρχει μόνος ένας κόμβος, τότε αυτός είναι η ρίζα, έχουμε φτάσει στην κορυφή του δέντρου και έχει προκύψει ένας τελικός κόμβος που περιέχει όλα τα δεδομένα. Οι πληροφορίες του R-tree και τα δεδομένα αποθηκεύονται σε ένα αρχείο κειμένου. Τα περιεχόμενα του αρχείου κειμένου εξάγονται από τον πίνακα nodes ο οποίος περιέχει όλους τους κόμβους του δέντρου. Η πρώτη γραμμή του txt περιέχει το node id της ρίζας, και από την δεύτερη γραμμή και κάτω παρατίθενται ο κάθε κόμβος με αύξοντα αριθμό βάσει το node id. Η δομή των leaf nodes είναι (nodeId, αριθμός φύλλων στον κόμβο, 0, ((recordId σημείου, [x,y]), ...)), ενώ των εσωτερικών κόμβων είναι (nodeId, αριθμός mbrs στον κόμβο, 1, ((nodeId του mbr, [xmin,ymin, xmax, ymax]), ...)). Τέλος στο τερματικό εκτυπώνονται στατιστικά του δέντρου, όπως το ύψος του, αριθμό κόμβων σε κάθε επίπεδο και το μέσο εμβαδό των mbr σε κάθε επίπεδο.

Διαχείριση Σύνθετων Δεδομένων
ΕΡΓΑΣΙΑ 2 – Χωρικά Δεδομένα
REPORT

Μέρος 2

Στην δεύτερη άσκηση παίρνουμε τα δεδομένα του δέντρου από το txt αρχείο. Για να επιτύχουμε την σωστή λειτουργία του αλγόριθμου, δημιουργήθηκαν δύο έξτρα κλάσεις, η PqEntry, η οποία είναι υπεύθυνη για την διαχείριση των αντικειμένων που προστίθενται στην ουρά, και η INNS, η οποία είναι υπεύθυνη για την αρχικοποίηση και τις λειτουργίες επεξεργασίας της ουράς. Αρχικά διαβάζεται η πρώτη γραμμή, η οποία περιέχει το nodeId της ρίζας. Φτιάχνουμε ένα νέο πίνακα ο οποίος θα περιέχει όλους τους κόμβους του δέντρου. Αυτό γίνεται ώστε το αρχείο στο οποίο έχει αποθηκευτεί το δέντρο να διαβαστεί εξ ολοκλήρου και να φτιαχτεί μια αναπαράσταση του δέντρου στη μνήμη όπως και στο 1ο μέρος της άσκησης πριν αρχίσει η αναζήτηση στο δέντρο. Για κάθε mbr, ή σημείο αν έχουμε φτάσει σε κόμβο φύλλο, βρίσκεται η απόσταση από το σημείο με την βοήθεια των μεθόδων minDistMBR και minDistPoint αντίστοιχα. Η λογική πίσω και από τις δύο μεθόδους είναι να εντοπιστεί η απόσταση του σημείου, αναλόγως με το αν βρίσκεται αριστερά ή δεξιά, από το mbr ή το σημείο. Όταν υπολογίζεται η απόσταση, τοποθετείται σε ένα priority queue ένα αντικείμενο PqEntry, το οποίο κρατάει πληροφορίες για την απόσταση, το nodeId και αν είναι φύλλο. Στο priority queue τα στοιχεία ταξινομούνται σύμφωνα με την απόσταση, οπότε αυτό με την μικρότερη απόσταση βρίσκεται στην κορυφή της ουράς. Μόλις τελειώσει η τοποθέτηση των στοιχείων αφαιρείται το στοιχείο που είναι ψηλότερα στην ουρά. Αν το στοιχείο που αφαιρέθηκε είναι σημείο, εκτυπώνεται και ξεκινά νέα αναζήτηση για τον αμέσως επόμενο κοντινότερο γείτονα έως ότου βρεθούν οι πρώτοι k γείτονες. Όσο το στοιχείο που βρίσκεται στην κορυφή της λίστας είναι φύλλο, αφαιρείται από την ουρά και εκτυπώνεται χωρίς να γίνεται νέα αναζήτηση στο δέντρο, αφού βρισκόμαστε ήδη στο κατώτερο επίπεδο. Αν δεν είναι φύλλο, τότε προστίθενται στην ουρά οι κόμβοι που βρίσκονται στο κατώτερο επίπεδο του κόμβου που αφαιρέθηκε, δηλαδή πρακτικά οι κόμβοι ή τα φύλλα που περιείχε ο κόμβος που αφαιρέθηκε από την λίστα. Μετά για να βρούμε τον k+1 και k+2 γείτονα, ακολουθείται η ίδια διαδικασία, δηλαδή, τρέχει ο αλγόριθμος από το σημείο που είχε μείνει και ψάχνει για το κοντινότερο γείτονα του. Συνοπτικά, τρέχει από το σημείο που σταμάτησε (θα συνεχίζει) για να βγάλει τον k+1 και στην συνέχεια τρέχει από το σημείο που σταμάτησε για να βγάλει τον k+2.