

Διαχείριση Σύνθετων Δεδομένων
ΕΡΓΑΣΙΑ 3 – Ερωτήσεις κορυφαίων κ και κορυφογραμμής
REPORT

Ευάγγελος Μπασδαβάνος

AM: 4962

Μέρος 1: Αλγόριθμος A top-k join

Ο αλγόριθμος επεξεργάζεται δύο αρχεία εισόδου που είναι ταξινομημένα: ένα που περιέχει δεδομένα για άντρες (males_sorted) και ένα άλλο για γυναίκες (females_sorted). Ο κύριος στόχος του προγράμματος είναι να βρει και να εκτυπώσει τα k καλύτερα ζευγάρια με τον υψηλότερο συνολικό score, υπό ορισμένες προϋποθέσεις. Το πρόγραμμα ξεκινά διαβάζοντας την τιμή του k (τον αριθμό των κορυφαίων ζευγαριών που πρέπει να βρεθούν) από τα ορίσματα γραμμής εντολών. Στη συνέχεια, δημιουργεί αντικείμενα BufferedReader για τα αρχεία εισόδου των αντρών και των γυναικών. Η μέθοδος readFile διαβάζει γραμμή-γραμμή είτε από το αρχείο των αντρών είτε από το αρχείο γυναικών, εναλλάξ. Η ανάγνωση ξεκινάει από το αρχείο των αντρών. Φιλτράρει τις γραμμές οι οποίες πληρούν τα δεδομένα, δηλαδή όποιο άτομο είναι μη παντρεμένο και άνω των 18 ετών και εξάγει τα σχετικά πεδία δεδομένων (ID, ηλικία, οικογενειακή κατάσταση, instance weight και φύλο) και τα αποθηκεύει σε ένα ArrayList. Η μέθοδος updateHashMaps ενημερώνει τον αντίστοιχο hash map με τα δεδομένα του νέου ατόμου που ανακτήθηκαν από το αρχείο, διατηρώντας μια λίστα με άτομα ανά ηλικία και παρακολουθώντας τον μέγιστο instance weight για κάθε φύλο. Η μέθοδος findTopCouple πρακτικά συντονίζει όλη τη διαδικασία ανάγνωσης δεδομένων, ενημέρωσης των hash maps και ελέγχου των πιθανών ζευγαριών. Ανάλογα με το φύλο του τρέχοντος ατόμου, ενημερώνει είτε τον hash map των αντρών είτε των γυναικών και υπολογίζει το κατώφλι T. Εάν βρεθεί άτομο ίδιας ηλικίας στο hash map του αντίθετου φύλου, υπολογίζει τον συνολικό instance weight, το οποίο είναι το άθροισμα των instance weight τους, και προσθέτει το πιθανό ζευγάρι σε μια ουρά προτεραιότητας. Η ουρά προτεραιότητας είναι μια max-heap που περιέχει τα ζευγάρια με τα υψηλότερα instance weights. Πρακτικά μόλις προστεθούν νέα ζευγάρια στο max heap γίνεται έλεγχος για το αν το άθροισμα των μισών βαρών τους είναι μεγαλύτερο από το κατώφλι. Αν είναι τότε πληρούν τις προϋποθέσεις και εκτυπώνονται και ο αλγόριθμος συνεχίζει για να βρει τα επόμενα ζευγάρια που θα προστεθούν στο max heap, αν ο αριθμός των ζευγαριών που ανακτήθηκε είναι μικρότερος από k.


Διαχείριση Σύνθετων Δεδομένων
ΕΡΓΑΣΙΑ 3 – Ερωτήσεις κορυφαίων κ και κορυφογραμμής
REPORT

Μέρος 2: Αλγόριθμος B top-k join

Αρχικά, ο αλγόριθμος διαβάσει τα δεδομένα των ανδρών από το αρχείο "males_sorted" και τα αποθηκεύει σε έναν HashMap. Κάθε γραμμή από το αρχείο διαβάζεται και ελέγχεται αν πληροί τα κριτήρια που έχουν οριστεί (δηλαδή, αν ο άνδρας δεν είναι παντρεμένος και αν είναι τουλάχιστον 18 ετών). Για κάθε άνδρα που πληροί τα κριτήρια, δημιουργείται μια λίστα με τις πληροφορίες του και προστίθεται στον hash map, όπου το κλειδί είναι η ηλικία του άνδρα. Στη συνέχεια, ο αλγόριθμος διαβάσει τα δεδομένα των γυναικών από το αρχείο "females_sorted". Για κάθε γυναίκα που πληροί τα ίδια κριτήρια (όχι παντρεμένη και τουλάχιστον 18 ετών), γίνεται αναζήτηση στο hash map των ανδρών για άνδρες που έχουν την ίδια ηλικία με την γυναίκα. Αν βρεθούν άνδρες της ίδιας ηλικίας, δημιουργούνται ζευγάρια με κάθε έναν από αυτούς τους άνδρες, με την γυναίκα, και υπολογίζεται ένα σκορ για κάθε ζευγάρι. Το σκορ αυτό είναι το άθροισμα των Instance weights του άνδρα και της γυναίκας. Τα ζευγάρια με τα υψηλότερα σκορ αποθηκεύονται σε ένα min heap που διατηρεί τα κορυφαία ζευγάρια βάσει του σκορ, με το ζευγάρι με το μικρότερο σκορ να βρίσκεται στην κορυφή του heap. Το priority queue διατηρεί μόνο τα k κορυφαία ζευγάρια, όπου k είναι ένας αριθμός που δίνει ο χρήστης στο cmd. Κάθε φορά που δημιουργείται ένα νέο ζευγάρι, ελέγχεται αν το σκορ του είναι μεγαλύτερο από το σκορ του ζευγαριού που βρίσκεται εκείνη την στιγμή στο min heap. Αν είναι, τότε αφαιρείται αυτό που είναι στην κορυφή, και την θέση του παίρνει το νέο ζευγάρι που μόλις δημιουργήθηκε. Τέλος, το πρόγραμμα εξάγει τα κορυφαία ζευγάρια από το min heap και τα εκτυπώνει με φθίνουσα σειρά σκορ.

Διαχείριση Σύνθετων Δεδομένων
ΕΡΓΑΣΙΑ 3 – Ερωτήσεις κορυφαίων κ και κορυφογραμμής
REPORT

Μέρος 3: Γραπτό μέρος



Αριθμός έγκυρων γραμμών που έχει διαβάσει ο αλγόριθμος A από κάθε αρχείο, για κάθε k:

k	males_sorted	females_sorted
1	44	44
2	134	134
5	437	437
10	1145	1145
20	2656	2656
50	6030	6030
100	10139	10139

Στον αλγόριθμο B, πριν αρχίσει να εκτυπώνει τα αποτελέσματα, διαβάζει όλο το αρχείο των αντρών και τους τοποθετεί σε ένα hashmap. Έπειτα διαβάζει, επίσης, όλο το αρχείο των γυναικών, και για κάθε match ελέγχει αν το score, του ζευγαριού που δημιουργήθηκε, είναι μεγαλύτερο από αυτό που βρίσκεται στην κορυφή του heap. Αν είναι τότε αφαιρεί αυτό που βρίσκεται στην κορυφή και προσθέτει το match στο minheap. Στο τέλος εκτυπώνει τα ζευγάρια που βρίσκονται στο minheap με αντίθετη σειρά από αυτή που βρίσκονται τοποθετημένα μέσα στο heap.

Διαχείριση Σύνθετων Δεδομένων
ΕΡΓΑΣΙΑ 3 – Ερωτήσεις κορυφαίων κ και κορυφογραμμής
REPORT

Στην υλοποίηση A, αρχίζει η ανάγνωση από το αρχείο των ανδρών και αποθηκεύει τα στοιχεία του, αν πληροί τις προϋποθέσεις, σε ένα hashmap. Έπειτα, διαβάζει μία γραμμή από το αρχείο των γυναικών και αν βρεθεί άντρας ίδιας ηλικίας με εκείνη, δημιουργείται ζευγάρι και προστίθεται στο max-heap. Μόλις βρεθούν όλα τα ζευγάρια της γυναίκας με άνδρες ίδιας ηλικίας, ελέγχεται το priority queue και όσων ζευγαριών το άθροισμα των μισών των βαρών τους ξεπερνά το κατώφλι, εκτυπώνονται. Όλη αυτή η διαδικασία γίνεται μέχρι να εκτυπωθούν όλα τα ζευγάρια ζήτησε ο χρήστης.

Αρχικά ο αλγόριθμος A ενημερώνει δυναμικά το σκορ και τα ζευγάρια καθώς διαβάζει νέα δεδομένα. Αυτό σημαίνει ότι δεν χρειάζεται να φορτώσει όλα τα δεδομένα στη μνήμη από την αρχή και να εκτυπώσει μετά τα κορυφαία ζευγάρια. Αντιθέτως, ο αλγόριθμος B μπορεί να καταναλώσει περισσότερη μνήμη καθώς φορτώνει όλα τα δεδομένα στη μνήμη πριν αρχίσει να επεξεργάζεται τα ζευγάρια.

Επίσης, ο αλγόριθμος A ελέγχει σχεδόν ταυτόχρονα τα δεδομένα ανδρών και γυναικών κατά την ανάγνωση και ενημέρωση των hashmap και εκτυπώνει τα αποτελέσματα μόλις βρει ένα ζευγάρι που πληροί τα κριτήρια, επιτρέποντας έτσι την άμεση παρουσίαση των αποτελεσμάτων χωρίς να χρειάζεται να περιμένει την ολοκλήρωση της επεξεργασίας όλων των δεδομένων από τα αρχεία. Από την άλλη ο B, πρέπει να διαβάσει όλα τα δεδομένα πριν μπορέσει να υπολογίσει και να εκτυπώσει τα αποτελέσματα. Αυτό προκαλεί καθυστερήσεις στην παρουσίαση των αποτελεσμάτων. Μπορούμε να παρατηρήσουμε αυτές τις καθυστερήσεις και από το διάγραμμα παραπάνω, ο αλγόριθμος A παίρνει περισσότερο χρόνο όσο αυξάνονται οι τιμές που ζητάει ο χρήστης αλλά και πάλι πολύ λιγότερο χρόνο από τον B. Ο B χρειάζεται σχεδόν σταθερό χρόνο, καθώς ανεξαρτήτως των πόσων ζευγαριών ζήτησε ο χρήστης ελέγχει ολόκληρα τα αρχεία.

Παρόλαυτα, ο αλγόριθμος B παραμένει πολύ πιο απλός από τον A καθώς η λογική που ακολουθεί είναι πολύ συγκεκριμένη, και δεν χρειάζεται να διαχειριστεί την εναλλαγή μεταξύ της ανάγνωσης δεδομένων από τα δύο αρχεία. Η λογική του A είναι πιο σύνθετη λόγω της εναλλαγής μεταξύ της ανάγνωσης ανδρών και γυναικών και της δυναμικής ενημέρωσης των πινάκων και του σκορ.